

1. Dinámica del sistema

Este TFG se basa en el estudio y análisis de una red neuronal que evoluciona mediante una dinámica anti-hebbiana (1), (2).

$$\dot{X} = WX \quad (1)$$

$$\dot{W} = \alpha(I - XX^T) \quad (2)$$

1.1. Dinámica de W y sus autovalores

Como PATATA se observa de la dinámica de W (2), la única parte de la matriz que evoluciona es la parte simétrica, por lo que como los autovalores de una matriz simétrica son puramente reales y de la antisimétrica puramente imaginarios, es razonable pensar que en los autovalores de la matriz W solo (o mayormente) evolucione la parte real mientras que la imaginaria quede perturbada mínimamente (ver Figura 1). Los resultados replican los de [1].

Además la frecuencia de las oscilaciones de la parte real de los autovalores muestra una dependencia lineal con $\sqrt{\alpha}$ como indica [1]




Figura 1: Evolución temporal de la parte real (**Izda.**) e imaginaria (**Dcha.**) de los autovalores de la matriz de conexiones, W , con entradas $W_{ij} \sim \mathcal{N}(0, 1)$, para $N = 20$, $\alpha = 0,001$. La parte real de los autovalores positivos disminuye rápidamente en escala de tiempo $t_+ \simeq 1$, mientras que la parte negativa aumenta hasta 0 en escalas de $t_- \simeq 10^3 = \frac{1}{\alpha}$, y como para tiempos mayores que t_- la parte real oscila en torno a 0. La parte imaginaria se mantiene constante en promedio excepto por ligeras perturbaciones que ocurren cuando la parte real del autovalor alcanza el máximo.

2. Actividad neuronal

2.1. PCA

Para comprobar si aparece criticidad, una vez el sistema se ha estabilizado en el régimen en el que los autovalores oscilan en torno al 0 se ha llevado a cabo un análisis componentes principales de la red neuronal calculando la distribución de autovalores del espectro de la matriz de covarianza de X a lo largo del tiempo buscando una ley de potencias.




Figura 2: Autovalores de la matriz de covarianza de la serie temporal de X ordenados de mayor a menor en escala lineal para $N = 500$, $\alpha = 0,0001$. No se ajusta a una ley de potencias, lo que indica la ausencia de criticidad del sistema.

2.2. Análisis de los picos de actividad

Analizando la serie temporal de X y la de los autovalores de W se observa una correlación entre los picos de actividad en X y los puntos en los que los autovalores de W “caen” desde $Re(\lambda) > 0$ hasta $Re(\lambda) < 0$. Intuitivamente cuando $X \sim 0$, W y por tanto sus autovalores crecen de forma lineal con $\dot{W} = \alpha$, asimismo X evoluciona de forma exponencial con la parte real de λ , por lo que una vez que $Re(\lambda) > 0$, X crece exponencialmente hasta que $XX^T \gg I$, cuando aparece un pico en la actividad. Una vez que X ha dejado de ser insignificante W empieza a decrecer hasta hacerse $Re(\lambda) < 0$, por lo

que genera que $X \sim 0$ y vuelve el ciclo. Este proceso se muestra en la Figura 3

Como X es una combinación lineal de los autovectores de W este proceso se llevará a cabo con cada autovalor, por lo que para N pequeño se verán picos diferenciados ya que la distancia entre caídas de autovalores es apreciable, mientras que para N muy grandes, p.ej. 100, la distancia entre caídas de autovalores es tan pequeña que las excitaciones se solapan hasta asemejarse a ruido estocástico, pero conteniendo cierta periodicidad (la de las oscilaciones de los autovalores).




Figura 3: Representación de la correlación entre caídas de autovalores y picos de actividad para $N = 7$, $\alpha = 0,0001$. **Izda.:** Evolución de dos de los autovalores de la matriz de conexiones, resaltando las caídas de $Re(\lambda)$ para cada uno de ellos. **Dcha.:** Actividad de la red calculada como $|X|^2$, donde se observa cómo los picos corresponden con las caídas en el espacio de autovalores. Los picos sin resaltar corresponden con otros autovalores que no se muestran en la gráfica.

3. Reunión 5/05/2026

3.1. Error tipográfico

En el código proporcionado por [2] aparece un error en el cálculo del x promediado por un filtro pasa-baja en el que no se actualiza correctamente el valor de `xlp`, sin embargo al corregirlo no varía de forma sustancial el resultado.

```
1 | x_all (: , i ) = x ;
```

```

2  r = tanh ( x ) ;
3  xlp = xlp + (( - xlp + x /1 e -2) / taux ) * dt ;
4  input = input + ( - zeta * input + randn * input1 (: ,
      i ) +
5  randn * input2 (: , i ) ) * dt ;

```

3.2. Linealidad

El trabajo de Susman et al. [2] emplea un modelo no lineal para la evolución tanto de las conexiones entre neuronas como para la tasa de disparo, empleando la función $\tanh(x)$ para suavizar el input. Además en la homeostásis anti-hebbiana se añade un término $\tilde{x}$ por alguna razón.

$$\begin{aligned}
\dot{x} &= -x + W \tanh(x) + b(t) \\
\dot{W} &= \underbrace{B - \tanh(x - \tilde{x}) \tanh(x)^T}_{\text{Decorrelación}} + \underbrace{\tanh(x) y^T - y \tanh(x)^T}_{\text{STDP}} + \xi(t) \\
\tau_y \dot{y} &= -y + \tanh(x) \\
\tau_x \dot{\tilde{x}} &= -\tilde{x} + x
\end{aligned}$$

Mi modelo es completamente lineal y no se le añade ningún término a la homeostásis, por lo que esta es puramente simétrica como se aplica en [1].

$$\begin{aligned}
\dot{x} &= Wx + b(t) \\
\dot{W} &= \underbrace{I - xx^T}_{\text{Anti-hebbiano}} + \underbrace{xy^T - yx^T}_{\text{STDP}} + \xi(t) \\
\tau_y \dot{y} &= -y + x
\end{aligned}$$

La figura 4 muestra una comparación entre los resultados obtenidos mediante el modelo de [2] (**Dcha**) y el mío (**Izda**) donde se observa cómo no es necesaria la no linealidad para mostrar la generación de memorias uardadas como un par de autovalores complejos conjugados. Ambas simulaciones se han llevado a cabo en Matlab usando el script de github de [2] cambiando los parámetros para añadir la linealidad.




Figura 4: Evolución temporal de la parte real (arriba) e imaginaria (abajo) de los autovalores de W . Se observa como el resultado de la ecuación con la no linealidad $\tanh(x)$ (**Dcha.**) y la linealizada (**Izda.**) no cambia de forma significativa y es cualitativamente idéntica.

3.3. Inconsistencia con la semilla

Sin embargo al no ser capaz de replicar los resultados en python en mi propio código e intentar traducir el código de matlab directamente a python me di cuenta de que si simplemente cambiaba la semilla del generador de números aleatorios el resultado cambiaba drásticamente




Figura 5: Diferentes simulaciones para el modelo no lineal en Matlab empleando diferentes semillas para el generador de números aleatorios: 12, 123, 234 y 537 de izquierda a derecha y de arriba a abajo.

Referencias

- [1] Marcelo O. Magnasco, Oreste Piro, and Guillermo A. Cecchi. Self-Tuned Critical Anti-Hebbian Networks. 102(25):258102.
- [2] Lee Susman, Naama Brenner, and Omri Barak. Stable memory with unstable synapses. 10(1):4441.